

Reporte de Evaluación del Voicebot Grupo Proaco — Inbound

Alcance: Flow **inbound** (cliente llama al bot) del proyecto **Proaco**. **Proyecto Opik:** voicebot-proaco-inbound-inbound · **Fecha de evaluación:** 2026-08-11 · **Juez:** Qwen 2.5 7B (Ollama, local)

> **Separación de análisis:** este reporte es solo Proaco inbound. El flow **outbound** > y el proyecto **AySA** se evalúan por separado (ver `proaco-evaluacion/README.md`).

1. Resumen Ejecutivo

Se evaluaron **13 llamadas reales** (transcripciones de pruebas manuales del voicebot) contra **7 métricas** basadas en las reglas de interacción del Grupo Proaco, usando un juez LLM local (Qwen 2.5 7B vía Ollama) a través del framework Opik. Luego se amplió con una **suite completa de 22 métricas** (heurísticas deterministas, LLM-judges genéricos y un segundo juez de comparación) — ver **Sección 10**.


Puntuación general: 0.77 / 1.00.


Área	Promedio	Lectura
Listado de propiedades	0.91	Sólido: respeta el máximo de 3 por mensaje y no agrega datos que no pidió el cliente.
Tono (español rioplatense)	0.81	Bueno, amable y claro en casi todas las llamadas.
Detección de intent	0.78	Detecta bien el flujo correcto, con algunos desvíos puntuales.
Derivación a la web	0.76	Falló en los casos donde el bot quedó atascado o no supo qué hacer.
Despedida	0.76	Varias llamadas terminan sin la despedida oficial.
Pedido de contacto (una vez)	0.70	Tendencia a repetir o a no pedir los datos.
Saludo oficial	0.64	Peor métrica: la llamada 5 ni siquiera arranca con el saludo.

Hallazgo principal: 3 de las 13 llamadas (23%) son críticas y explican casi todo el déficit: la **llamada-5** (loop con cliente que pide un humano), la **llamada-10** (despedida ausente) y la **llamada-12** (no deriva pese a no poder resolver). El resto del sistema se comporta bien (llamada-8: 0.89, llamada-3: 0.87).

2. Proceso de Evaluación

2.1 Pipeline





Etapas: 1. **Parseo del CSV** (proaco-evaluacion/proaco/inbound/convertir_csv.py): detecta los bloques TEST N, separa turnos Agent/Caller y captura las etiquetas de herramientas (proaco_list_intent, getCalDotComAvailability, scheduleCalDotComAppointment, proaco_resolve_intent) en metadata.tools. El TEST 14 resultó un duplicado exacto del TEST 12 y se descartó (13 únicos). 2. **Normalización:** turnos [BOT]/[CLIENTE] para el juez (evaluar.py). 3. **Dataset en Opik:** transcripciones-proaco-inbound con los 13 items y su metadata. 4. **Evaluación:** evaluate() corre las 7 métricas LLM-as-judge sobre cada llamada (91 puntuaciones en total).

2.2 Métricas (reglas de Proaco)

Obligatorias (aplican a toda llamada): saludo_correcto, despedida_correcta, pide_contacto_una_vez, tono_espanol_argentino. Condicionales (solo si la situación se presenta): deteccion_intent, listado_max_3, deriva_web_si_no_sabe.

Cada métrica pide al juez un {"score": 0-1, "reason": "..."} con ejemplos de buen y mal cumplimiento.

2.3 Limitaciones metodológicas

- **Muestra pequeña** (13 llamadas): los promedios son indicativos, no estadísticamente robustos.
- **Juez local 7B:** consistente y sin costo, pero menos preciso que un juez grande; los scores son orientativos.
- **1 score fallido:** la métrica pide_contacto_una_vez de la llamada-5 no se computó (el juez devolvió JSON mal formado). Se muestra como no evaluada (n=12 en esa métrica).

3. Datos

3.1 Promedios por métrica

Métrica	Promedio	Mín	Máx	n
listado_max_3	0.91	0.60	1.00	13
tono_espanol_argentino	0.81	0.60	0.90	13
deteccion_intent	0.78	0.60	1.00	13
deriva_web_si_no_sabe	0.76	0.00	1.00	13
despedida_correcta	0.76	0.00	1.00	13
pide_contacto_una_vez	0.70	0.60	0.80	12
saludo_correcto	0.64	0.00	0.90	13

3.2 Resultados por llamada (promedio de las 7 métricas)

Llamada	Score	Intents/tools usados
llamada-8	0.89	list, availability, schedule

llamada-3	0.87	resolve
llamada-11	0.85	list, availability, schedule
llamada-1	0.83	list, availability, schedule
llamada-13	0.82	list, availability
llamada-6	0.80	list, availability, schedule
llamada-10	0.80	list
llamada-9	0.77	list, availability, schedule
llamada-7	0.76	list, availability
llamada-2	0.70	list, availability
llamada-4	0.70	resolve, availability
llamada-12	0.69	availability, schedule
llamada-5	0.43	— (sin intent detectado)

3.3 Casos con evidencia concreta (reasons del juez)

- **llamada-5** — `saludo=0.0`, `despedida=0.0`, `deriva_web=0.0`: "El bot no inicia la llamada con el saludo oficial... no sugiere consultar con Grupo Proaco... no se despide." El cliente pide un humano 6 veces y el bot responde siempre "no puedo transferir llamadas" → **loop de 12 turnos sin salida**.
- **llamada-10** — `despedida=0.5`: "El bot no utilizó la despedida oficial del Grupo Proaco." El cliente se despide ("eso es todo, hasta luego") y el bot no responde con el cierre oficial.
- **llamada-3** — `saludo=0.5`: "El bot inició con un saludo no oficial y luego cambió al saludo correcto."
- **llamada-12** — `deriva_web=0.0`: el bot no ofrece consultar en la web cuando no tiene turnos disponibles.

4. Conclusiones

1. **El núcleo del flujo inmobiliario funciona bien.** El listado de propiedades (máx. 3) y el tono argentino amable son las dos fortalezas del bot (0.91 y 0.81). Las llamadas con flujo completo listado + agenda de turno (1, 6, 8, 11) promedian 0.83-0.89.
2. **El problema está concentrado, no distribuido.** 3 llamadas explican la mayor parte del déficit. Si se corrigieran la 5, la 10 y la 12, el promedio global subiría de 0.77 a ≈0.83.
3. **Falta un protocolo de transferencia a humano.** La llamada-5 es el peor caso: ante "pásenme con un asesor humano", el bot se encierra en "no puedo transferir" y repite la misma respuesta 6 veces (rigidez conversacional).
4. **El protocolo de apertura y cierre es inconsistente.** El saludo oficial se pierde en al menos 2 llamadas y la despedida oficial en varias. Son reglas de *branding* que hoy se cumplen por azar del LLM, no de forma garantizada.
5. **Los datos de evaluación están correctos y completos** en Opik (experimento `dynamic_annuity_8219`), pero solo visibles en la pestaña *Experiments*: los traces generados por la evaluación son `source=experiment`, no `source=sdk`, por lo que *Logs* y *Dashboard* aparecen vacíos (ver apéndice A).

5. Recomendaciones

5.1 Prioridad alta

1. **Protocolo de derivación a humano.** Cuando el cliente pide explícitamente un humano (1ª vez): cortar el intent de venta, reconocer la solicitud, pedir datos de contacto para callback y dar la despedida oficial. Si no hay transferencia posible, decirlo una vez y cerrar con un mensaje de redirección (web o callback) — nunca repetir "no puedo transferir".
2. **Fijar saludo y despedida como texto predefinido (no generado).** Ambos son frases fijas de la marca; inyectarlas en el system prompt o como template al inicio/fin de cada turno elimina la variabilidad (0.64 y 0.76 son demasiado bajos para reglas obligatorias).
3. **Cerrar siempre la llamada, aunque el cliente se despida primero.** Cuando el cliente dice "hasta luego", el bot debe responder con la despedida oficial antes de terminar (corrige llamada-10).

5.2 Prioridad media

1. **Pedido de contacto una sola vez y al final.** La regla `pide_contacto_una_vez` (0.70) se viola tanto por repetir el pedido como por omitirlo. Unificar el flujo: al final del objetivo de la llamada, un único pedido de nombre + teléfono/mail, sin confirmar en eco lo que el cliente ya dio.
2. **Revisar el prompt de la herramienta de disponibilidad de turnos.** En llamada-12 el bot no sabe ofrecer alternativas ni derivar a la web cuando no hay turnos. El prompt de `getCalDotComAvailability` debería incluir el fallback a la web y opciones de otro día.
3. **Validar los datos de contacto que entrega el bot.** En la llamada-13 el bot entregó un teléfono y un mail de **AySA** (`atencionalusuario@aysa.com.ar`, `+54 11 5984 5794`) — datos de otro cliente del conocimiento (GAIL). Es un caso de *hallucination* de datos sensibles: auditar el conocimiento de contacto de Grupo Proaco y testear explícitamente esta consulta.

5.3 Prioridad baja / proceso

1. **Ampliar el dataset de evaluación.** 13 llamadas son pocas; agregar las variantes por intent (listado, turnos, resolución, rechazo a IA, salidas inesperadas) para estabilizar los promedios.
2. **Instrumentar el bot en producción con `opik.track()`.** Los traces de evaluación no aparecen en *Logs* ni *Dashboard* porque son `source=experiment`. Para monitoreo en vivo, correr el bot con el SDK de Opik (decorador `@track`) para que las llamadas reales generen traces `source=sdk` y se vean en las pestañas Logs/Dashboard (ver apéndice A).
3. **Agregar `error_count` a la cabecera de la evaluación:** el juez 7B falló en 1 de 91 respuestas JSON; repetir esa llamada en la próxima tanda para no perder la métrica.

6. Acciones a Seguir — Roadmap Priorizado

6.1 Plan de acción (4 fases)

Fase	Acción	Qué resuelve	Esfuerzo	Impacto esperado
------	--------	--------------	----------	------------------

F1 — Inmediata (0-2 semanas)	Corregir el protocolo de derivación a humano en la llamada-5	Loop sin salida, peor caso del dataset	Bajo (prompt)	0.43 → 0.80 en llamada-5
F1 — Inmediata (0-2 semanas)	Fijar saludo y despedida como texto predefinido, no generado	Reglas obligatorias más fallidas	Bajo (template)	saludo 0.64 → 0.95+; despedida 0.76 → 0.95+
F2 — Corto plazo (2-4 semanas)	Cerrar la llamada cuando el cliente se despide primero (despedida oficial)	llamada-10 y casos similares	Bajo (prompt)	despedida → 1.00
F2 — Corto plazo (2-4 semanas)	Unificar el pedido de contacto: una sola vez, al final	Regla pide_contacto_una_vez	Medio (flujo)	0.70 → 0.90
F3 — Mediano plazo (1-2 meses)	Corregir hallucination de datos de contacto (llamada-13: entregó datos de AySA)	Riesgo reputacional / datos erróneos	Medio (auditoría de conocimiento)	elimina riesgo de datos ajenos
F3 — Mediano plazo (1-2 meses)	Mejorar el fallback de la herramienta de disponibilidad (deriva a web y alternativas)	llamada-12, deriva_web 0.76	Medio (prompt + lógica)	deriva_web → 0.95
F4 — Continuo	Ampliar dataset a 25-30 llamadas por intent y reevaluar	Estabilidad de los promedios	Bajo (proceso)	métricas más confiables
F4 — Continuo	Instrumentar producción con <code>opik.track()</code> y monitorear en Logs/Dashboard	Visibilidad en vivo	Medio (SDK)	alertas tempranas de regresión

6.2 Métricas de éxito (objetivo para la próxima evaluación)

Métrica	Actual	Objetivo F2	Objetivo F3
saludo_correcto	0.64	0.95	1.00
despedida_correcta	0.76	0.95	1.00
pide_contacto_una_vez	0.70	0.85	0.90
deriva_web_si_no_sabe	0.76	0.85	0.95
deteccion_intent	0.78	0.90	0.95
listado_max_3	0.91	0.95	0.98
tono_espanol_argentino	0.81	0.90	0.95
Promedio general	0.77	0.91	0.96

7. Recomendaciones para Mejora por Área

7.1 Conversacional / UX

- Anticipar la objeción "¿es una IA?":** responder con transparencia y ofrecer inmediatamente la opción de callback humano, en lugar de negar la transferencia.
- Límite de reintentos:** si el bot repite la misma respuesta 2 veces seguidas, cambiar de estrategia (derivar, dar la web, o cerrar con despedida oficial). Regla dura en el orquestador.

- **Detectar despedida del cliente como trigger de cierre:** si el cliente dice "hasta luego / chau / eso es todo", el bot debe responder con la despedida oficial y finalizar (no seguir preguntando).
- **No hacer eco de datos:** cuando el cliente ya dio su nombre/teléfono, el bot no debe repetirlos ni pedirlos de nuevo.

7.2 Datos y conocimiento

- **Auditar el "knowledge base" de contacto:** verificar que los teléfonos/emails/marcas de Grupo Proaco estén aislados de los de otros clientes del GAIL. La llamada-13 devolvió datos de AySA: revisar el prompt de sistema y la fuente de conocimiento.
- **Versionar los prompts:** guardar cada versión del system prompt y de las herramientas con nombre/versión para poder comparar evaluaciones (regresión).
- **Agregar casos adversariales al dataset:** cliente agresivo, cliente con datos erróneos, consultas fuera de alcance, cortes de llamada.

7.3 Evaluación y monitoreo

- **Reevaluar en CI/CD:** correr `evaluar.py` en cada cambio de prompt/knowledge base y comparar contra el baseline (0.77).
- **Juez más fuerte para datos sensibles:** las reglas de contacto deberían evaluarse también con un juez más grande (o verificación determinista: buscar los strings oficiales en la respuesta).
- **Verificación determinista complementaria:** para `saludo_correcto` y `despedida_correcta`, chequear la presencia de las frases oficiales exactas (no depender solo del LLM).

8. Alternativas de Solución por Problema

Problema	Opción A (recomendada)	Opción B	Opción C
Loop con cliente que pide humano	Protocolo de derivación a humano (callback + despedida)	Transferencia a agente en vivo si la plataforma lo permite	Respuesta única "no puedo transferir" + redirección web y cierre
Saludo/despedida inconsistentes	Texto fijo inyectado al inicio/fin de cada llamada	Regla en el orquestador que fuerza la frase	Post-procesamiento que reemplaza el saludo si no coincide
No deriva a la web cuando no sabe	Prompt de herramientas con fallback explícito a la URL	Regla condicional en el flujo: si no hay turnos → sugerir web	Mayor conocimiento local (FAQ) para reducir consultas no resueltas
Hallucination de datos de contacto (AySA)	Aislar el knowledge base de Grupo Proaco por cliente	Restringir a tokens/entidades permitidas (whitelist de contactos)	Verificación determinista de contacto antes de responder
Datos de contacto pedidos varias veces	Unificar pedido al final de la llamada	Estado de máquina que solo permite 1 pedido por llamada	Confirmación silenciosa (no eco)

9. Próximos Pasos Sugeridos

1. **Hoy:** aplicar el fix F1 de saludo/despedida como texto fijo y re-evaluar (≈30 min).
2. **Esta semana:** corregir el protocolo de derivación a humano (llamada-5) y re-evaluar.

- 3. **Semanas 2-4:** auditar el knowledge base de contacto (AySA) y agregar la verificación determinista de las frases oficiales.
- 4. **Mes 1:** instrumentar el voicebot con `opik.track()` para monitoreo en Logs/Dashboard.
- 5. **Mes 1-2:** ampliar el dataset de evaluación y establecer el baseline de regresión en CI.

10. Pruebas Ampliadas (Suite Completa de Métricas)

Sobre las mismas 13 llamadas se corrió una **suite completa de pruebas** (`pruebas_ampliadas.py`) con 3 bloques: heurísticas deterministas (sin LLM), métricas LLM-judge genéricas de Opik, y las reglas de Proaco con un segundo juez local para comparar consistencia.

10.1 Suite 1 — Heurísticas deterministas (sin LLM)

Reglas verificables con texto plano, rápidas y 100% reproducibles. Aplican sobre la transcripción completa, no sobre el último turno.

Métrica	Promedio	Lectura
Adherencia al español	1.00	13/13 en español rioplatense.
Tono respetuoso	1.00	Sin insultos, gritos ni exclamaciones excesivas.
Sin loop "no puedo transferir"	0.92	Solo falla la llamada-5 (8 menciones → loop).
Sin hallucination de AySA	0.92	Solo falla la llamada-13 (cita <code>atencionalusuario@aysa.com.ar</code>).
Despedida presente	0.85	11/13 cierran correctamente; fallan llamada-2 y llamada-12.
Saludo presente	0.31	Solo 4/13 arrancan con saludo; el resto comienza con "Claro, puedo ayudarle...".
URL de derivación presente	0.31	Solo 4/13 muestran <code>grupoproaco.com/unidades</code> cuando no saben responder.

Correlación con el juez LLM: el saludo determinista (0.31) es **más estricto** que el juez LLM (0.64) porque exige literalmente un saludo al inicio, mientras el juez acepta respuestas que "conversan" sin saludar. La despedida coincide (0.85 vs 0.76). Confirmado: **el déficit real está en el saludo de apertura**, no solo en el texto oficial.

10.2 Suite 2 — Métricas LLM-judge genéricas de Opik (juez qwen2.5:7b)

Miden atributos transversales del diálogo, independientes de las reglas de Proaco.

Métrica	Promedio	Lectura
Agent tool correctness	0.72	El uso/interpretación de tools es razonablemente correcto.
Session completeness	0.69	La sesión cierra los objetivos la mayoría de las veces.
Coherencia conversacional	0.65	Diálogo coherente; los desvíos bajan el promedio.
Usefulness	0.37	Bajo por el encuadre: evalúa si el <i>*último turno*</i> responde la <i>*primera*</i> pregunta (marco distinto al real).
Task completion	0.36	Bajo por la misma razón de encuadre + casos atascados (llamada-5/8/13).
Answer relevance	0.31	Igual efecto de encuadre: el último turno no retoma la pregunta inicial.

User frustration	0.09	Muy bajo = pocas señales de frustración (buena noticia). Solo la llamada-5 muestra frustración alta (0.88).
Moderation	0.00	Métrica no válida con este juez local: qwen devuelve 0 en contenido benigno (incompatibilidad de parser). Descartar o usar un modelo de moderación dedicado.

Interpretación: usefulness/task_completion/answer_relevance miden el par *primera pregunta del cliente → última respuesta del bot*; como la conversación evoluciona, esos scores subestiman la utilidad real. Las métricas de conversación (coherencia, frustración, completitud) son más representativas del comportamiento real.

10.3 Suite 3 – Comparación de jueces (qwen2.5:7b vs qwen2.5-coder:7b)

Las 7 reglas de Proaco se repitieron con el segundo juez local para medir consistencia del evaluador.

Métrica	qwen2.5:7b	qwen2.5-coder:7b	Δ
Tono rioplatense	0.81	0.84	+0.03
Detección de intent	0.78	0.79	+0.00
Pedido de contacto	0.70	0.71	+0.01
Derivación a web	0.76	0.62	-0.15
Listado máx. 3	0.91	0.64	-0.27
Despedida	0.76	0.51	-0.25
Saludo	0.64	0.25	-0.38

Conclusión: el juez coder es **significativamente más estricto** en reglas textuales (saludo -0.38, listado -0.27, despedida -0.25) y casi igual en las conductuales (tono, intent, contacto). La diferencia no cambia las prioridades (saludo sigue siendo lo peor con ambos jueces), pero confirma que **el score absoluto depende del juez**: hay que fijar UN juez como baseline (recomendado: qwen2.5:7b) y no mezclar jueces entre corridas.

10.4 Detección cruzada de anomalías

Anomalía	Suite 1 (determinista)	Suite 2 (LLM-judge)	Suite 3 (juez 2)
Llamada-5: loop sin transferencia	Loop 8x (sin_loop=0)	Frustración 0.88, completitud 0	Todo 0 salvo tono
Llamada-13: hallucination AySA	sin_datos_aysa=0	Tool correct 1.0 pero task completion 0	Deriva web 0
Llamada-12: sin despedida ni deriva	Despedida 0, URL 0	Coherencia 0.19, completitud 0	Saludo 0
Llamada-10: despedida ausente (pero resuelve)	Despedida 1, URL 0	Coherencia 1.0, completitud 1.0	Todo alto salvo despedida

Las 3 suites convergen en los mismos casos problema, lo que valida la evaluación original.

10.5 Resumen de artefactos nuevos

Suites	Código	Experimento Opik
Suite 1 — Heurísticas	pruebas_ampliadas.py (funciones suite_heuristicas/clases MetricaTranscripcion)	heurísticas-deterministas

Suite 2 — LLM-judges	<code>suite_llm_judges</code>	<code>llm-judges-adicionales</code>
Suite 3 — Juez 2	<code>suite_reglas_proaco</code>	<code>reglas-proaco-juez-qwen2.5-coder:7b</code>
Descarga de resultados	<code>descargar_resultados.py</code> → <code>resultados_suites.json</code>	—

> **Nota de ejecución:** las suites LLM deben correr con `task_threads=1`; con la concurrencia por defecto (16 hilos) Ollama se cuelga y `evaluate()` queda sin progreso.

Apéndice A — Por qué Logs y Dashboard están vacíos

Los trazes generados por `evaluate()` tienen `source=experiment` (15 trazes y 418 spans en el proyecto). La pestaña **Logs** filtra por `source=sdk` (trazes de aplicación en vivo) → 0 resultados. El **Dashboard** muestra KPIs sobre esos mismos trazes `sdk` → vacío. **No es un bug de datos:** los resultados están completos en **Experiments** (experimento `dynamic_annuity_8219`, 13 items con scores).

Para que una llamada aparezca en Logs/Dashboard, el voicebot debe ejecutarse con el SDK de Opik activo (ej. decorando la función de manejo del turno con `@opik.track(project_name="voicebot-proaco-inbound")`). Ejemplo mínimo:

```
python
import opik

opik.configure(project_name="voicebot-proaco-inbound", use_local=True)

@opik.track()
def atender_turno(mensaje_cliente: str) -> str:
    # ... lógica del voicebot ...
    return respuesta_del_bot
```

Apéndice B — Cómo reproducir la evaluación

```
bash
# 1. Convertir el CSV a JSON
.venv/bin/python proaco-evaluacion/proaco/inbound/convertir_csv.py

# 2. Correr la evaluación (requiere Ollama con qwen2.5:7b)
.venv/bin/python proaco-evaluacion/proaco/inbound/evaluar.py proaco-evaluacion/proaco/inbound/transcripciones/llamadas_reales.json

# 3. Suite ampliada (heurísticas sin LLM, rápida)
.venv/bin/python proaco-evaluacion/proaco/inbound/pruebas_ampliadas.py --solo suite1

# 4. Suite ampliada (LLM-judges + juez 2, lento: ~45-90 min)
.venv/bin/python proaco-evaluacion/proaco/inbound/pruebas_ampliadas.py --solo suite2
.venv/bin/python proaco-evaluacion/proaco/inbound/pruebas_ampliadas.py --solo suite3

# 5. Descargar resultados por llamada a resultados_suites.json
```

```
.venv/bin/python proaco-evaluacion/proaco/inbound/descargar_resultados.py

# 6. Ver resultados en el dashboard local
# http://localhost:5173/default/projects/voicebot-proaco-inbound/experiments
```

Escalar a cientos de llamadas (modo nube)

El juez es un modelo de LiteLLM: con un nombre que contiene / se usa el proveedor cloud en vez de Ollama. En nube los hilos por defecto son 8 (las APIs paralelizan); en Ollama 1 (evita cuelgues).

```
bash
# OpenAI (recomendado como baseline de regresión)
export OPENAI_API_KEY=sk-...
.venv/bin/python proaco-evaluacion/proaco/inbound/evaluar.py proaco-
evaluacion/proaco/inbound/transcripciones/llamadas_reales.json --juez openai/gpt-4o-mini

# Groq (free tier, muy rápido) – Llama 3.3 70B
export GROQ_API_KEY=gsk-...
.venv/bin/python proaco-evaluacion/proaco/inbound/pruebas_ampliadas.py --solo suite2 --juez groq/llama-
3.3-70b-versatile
.venv/bin/python proaco-evaluacion/proaco/inbound/pruebas_ampliadas.py --solo suite3 --juez2 groq/llama-
3.3-70b-versatile

# Gemini Flash (free tier)
export GEMINI_API_KEY=...
.venv/bin/python proaco-evaluacion/proaco/inbound/evaluar.py ... --juez gemini/gemini-2.0-flash
```

Costo aproximado con gpt-4o-mini: ~US\$2 por 500 llamadas × 7 reglas. **Regla crítica: fijar UN juez como baseline y no cambiarlo entre corridas** (cada juez puntúa distinto; vimos diferencias de hasta 0.38 entre dos qwen locales).

Archivos del pipeline: proaco-evaluacion/proaco/inbound/convertir_csv.py, proaco-evaluacion/proaco/inbound/evaluar.py, proaco-evaluacion/proaco/inbound/metricas_proaco.py, proaco-evaluacion/proaco/inbound/transcripciones/llamadas_reales.json.