

Reporte de Evaluación del Voicebot Grupo Proaco — Inbound + Outbound

Fecha: 2026-08-12 · **Flows:** inbound (cliente llama) y outbound (bot llama a leads) · **Juez:** Qwen 2.5 7B / 7B-Coder (Ollama local)

1. Inbound

Se evaluaron **13 llamadas inbound** con 4 suites: heurísticas deterministas, LLM-judges adicionales y las 7 reglas de Proaco con dos jueces (comparación de consistencia).

S1 · Heurísticas deterministas

Métrica		Promedio
~	URL de derivación	0.308
~	Saludo presente	0.308
⚠	Despedida presente	0.846
⚠	Sin loop de transferencia	0.923
⚠	Sin datos de AySA	0.923
⚠	Tono respetuoso	1.000
⚠	Adherencia a español	1.000

S2 · LLM-judges adicionales

Métrica		Promedio
⚠	Moderación	0.000
⚠	Frustración del usuario	0.094
✓	Correctitud de herramientas	0.300
~	Utilidad	0.323
~	Relevancia de respuesta	0.354
⚠	Compleitud de tarea	0.523
⚠	Compleitud de sesión	0.603
⚠	Coherencia conversacional	0.639

S3 · Reglas Proaco (juez qwen2.5:7b)

Métrica		Promedio
⚠	Pedido de contacto (una vez)	0.592
⚠	Saludo oficial	0.623
⚠	Despedida oficial	0.750
⚠	Detección de intent	0.754
⚠	Tono español rioplatense	0.819
⚠	Deriva a la web	0.831
⚠	Listado máximo 3	0.931

S3 · Reglas Proaco (juez qwen2.5-coder:7b)

Métrica		Promedio
~	Saludo oficial	0.350
~	Despedida oficial	0.492
⚠	Listado máximo 3	0.538
⚠	Pedido de contacto (una vez)	0.654
⚠	Detección de intent	0.765
⚠	Tono español rioplatense	0.865
⚠	Deriva a la web	0.885

2. Outbound

Se evaluaron **6 llamadas outbound** (touchpoints de la campaña Grupo Proaco en Lula). Nota: al momento de la evaluación la campaña solo contiene las llamadas de QA inbound; no hay llamadas salientes reales todavía.

O1 · Reglas outbound (heurísticas)

Métrica		Promedio
✓	Ofrece agendar cita	0.000
✓	Pide consentimiento	0.000
✓	Menciona el motivo	0.167
⚠	Listado máximo 3	0.833
⚠	Se presenta como Proaco	1.000
⚠	Tono respetuoso	1.000
⚠	Maneja no-interés	1.000

O2 · Reglas outbound (LLM-judge)

Métrica		Promedio
✓	Agendamiento de cita (LLM)	0.000
✓	Ofrece agendar cita	0.000
✓	Pide consentimiento	0.000
✓	Cliente no interesado (LLM)	0.133
✓	Menciona el motivo	0.167
△	Listado máximo 3	0.833
△	Maneja no-interés	1.000
△	Tono respetuoso	1.000
△	Se presenta como Proaco	1.000

3. Detalle por llamada

Cada llamada tiene su propia carpeta en `evaluaciones/{flow}/{llamada_id}/` con `scores.json`, `resumen.md` y `transcripcion.txt`.

Inbound

Llamada	S1	S2	S3	S3
llamada-1	0.71	0.40	0.83	0.83
llamada-10	0.71	0.49	0.81	0.79
llamada-11	0.71	0.32	0.86	0.46
llamada-12	0.57	0.22	0.66	0.60
llamada-13	0.86	0.34	0.81	0.99
llamada-2	0.57	0.42	0.69	0.48
llamada-3	0.71	0.34	0.90	0.93
llamada-4	0.86	0.48	0.81	0.59
llamada-5	0.71	0.30	0.37	0.34
llamada-6	0.86	0.29	0.74	0.51
llamada-7	1.00	0.30	0.73	0.39
llamada-8	0.86	0.28	0.87	0.93
llamada-9	0.71	0.43	0.76	0.63

Outbound

Llamada	O1	O2
CA18a4abd08a	0.57	0.44
CA19ee8401e8	0.71	0.64
CA1cc4b3a43b	0.57	0.44
CAc57514332e	0.57	0.44
CAd7af8dc9b3	0.43	0.33
CAf8fa6d0fc1	0.57	0.44

4. Hallazgos

Métricas con promedio bajo (< 0.60):

Métrica	Promedio	Suite
inbound/pide_contacto_una_vez	0.592	Reglas Proaco (juez qwen2.5:7b)
outbound/ofrece_agendar_cita	0.000	O1 · Reglas outbound (heurísticas)
outbound/pide_consentimiento	0.000	O1 · Reglas outbound (heurísticas)
outbound/menciona_proposito	0.167	O1 · Reglas outbound (heurísticas)
outbound/agendamiento_cita	0.000	O2 · Reglas outbound (LLM-judge)
outbound/ofrece_agendar_cita	0.000	O2 · Reglas outbound (LLM-judge)
outbound/pide_consentimiento	0.000	O2 · Reglas outbound (LLM-judge)
outbound/cliente_no_interesado	0.133	O2 · Reglas outbound (LLM-judge)
outbound/menciona_proposito	0.167	O2 · Reglas outbound (LLM-judge)

Recomendaciones

- **Inbound saludo/deriva:** reforzar el saludo oficial al inicio y la derivación a la web cuando el bot no puede resolver.
- **Inbound despedida/pedido de contacto:** asegurar despedida oficial y pedido de datos una sola vez al cierre.
- **Outbound:** validar las reglas con llamadas salientes reales (la campaña todavía no tiene). Se espera `pide_consentimiento` bajo si el flow no lo implementa.

Apéndice: Handoff y Próximos Pasos

HANDOFF — Evaluación Voicebot Proaco (Inbound + Outbound)

Fecha: 2026-08-12 Proyecto: proaco-evaluacion/ Git: inicializado (commit cfedb5a)

Qué se hizo

Flow	Llamadas	Suites	Juez
Inbound	13	4 (heurísticas, LLM-judges, 7-reglas juez1, 7-reglas juez2)	qwen2.5:7b / qwen2.5-coder:7b (Ollama local)
Outbound	6*	2 (heurísticas, LLM-judges GEval)	qwen2.5:7b

* Los 6 touchpoints outbound de la campaña "Grupo Proaco" en Lula son en realidad las mismas llamadas inbound de QA; **no hay llamadas salientes reales todavía.**

Estructura clave

```
proaco-evaluacion/
├─ evaluaciones/
│   └─ inbound/llamada-{1..13}/      # 13 carpetas, cada una con scores.json, resumen.md,
transcripcion.txt
│   └─ outbound/CA.../              # 6 carpetas (IDs de Lula)
│       └─ resultados_completos.json # agregado de todas las suites
├─ REPORTE_EVALUACION_PROACO.md      # reporte consolidado (inbound + outbound)
├─ REPORTE_EVALUACION_PROACO_INBOUND.md # reporte inbound legacy
├─ correr_todas.py                   # orquestador que corre todas las suites
├─ organizar_evaluaciones.py         # baja scores de Opik y arma carpetas por caso
├─ generar_reporte.py                # genera el reporte MD/HTML desde resultados_completos.json
├─ proaco/inbound/                   # código inbound (evaluar.py, pruebas_ampliadas.py, métricas)
└─ proaco/outbound/                  # código outbound (evaluar_outbound.py, exportar_outbound.py,
métricas)
```

Comandos útiles

```
bash
cd /Users/david899/Documents/Default\ Project/proaco-evaluacion

# Ver reporte
cat REPORTE_EVALUACION_PROACO.md
```

```
# Volver a armar carpetas + reporte (lee de Opik)
python organizar_evaluaciones.py
python generar_reporte.py

# Correr TODAS las suites de nuevo (lento: ~1.5h en Ollama)
python correr_todas.py

# Solo outbound LLM (GEval)
cd proaco/outbound
python -c "
from evaluar_outbound import cargar_items
items = cargar_items('transcripciones/llamadas_outbound.json')
import evaluar_outbound as eo
r = eo.run_evaluacion(items, llm=True, juez_modelo='qwen2.5:7b', threads=1)
"

# Exportar touchpoints frescos de Lula (requiere LULA_API_KEY)
export LULA_API_KEY="api-..."
python proaco/outbound/exportar_outbound.py

# Opik UI
open http://localhost:5173
# Proyectos: voicebot-proaco-inbound, voicebot-proaco-outbound
```

Hallazgos principales (del reporte)

Inbound (juez qwen2.5:7b): -  Fuerte: listado máx 3 (0.93), tono (0.82), deriva web (0.83) -  Débil: saludo oficial (0.62), pedido de contacto (0.59)

Inbound (juez qwen2.5-coder:7b) — más estricto: -  Saludo 0.35, despedida 0.49, listado máx 3 0.54

Outbound: - Todas las métricas de flow saliente en **0.00** (menciona_proposito, pide_consentimiento, ofrece_agendar_cita, GEval) porque **no hay llamadas outbound reales** en la campaña Lula — solo touchpoints de QA inbound.

Próximos pasos sugeridos

1. **Esperar llamadas outbound reales** en la campaña "Grupo Proaco" (Lula) → volver a correr exportar_outbound.py + correr_todas.py --solo outbound.
2. **Probar juez cloud** (Grok llama-3.3-70b-versatile gratis, o OpenAI gpt-4o-mini) para acelerar y evitar throttle térmico.
3. **Refinar heurística maneja_no_interes** (falso positivo por "gracias" en saludo).

Configuración de entorno

- **Ollama:** qwen2.5:7b, qwen2.5-coder:7b (throttle ~7 tok/s en MacBook Air M4 16GB)
 - **Opik local:** Docker en localhost:5173
 - **Lula API:** https://api.lula.com + header X-API-Key (export LULA_API_KEY)
 - **Python venv:** .venv/ en la raíz del proyecto
-

Para retomar en nueva sesión

```
bash
cd /Users/david899/Documents/Default\ Project/proaco-evaluacion
cat REPORTE_EVALUACION_PROACO.md
cat evaluaciones/resultados_completos.json | head -50
```