

Leyenda: ■ Bueno (≥ 0.75) ■ Regular (0.50 – 0.74) ■ Crítico (< 0.50)

Reporte de Evaluación del Voicebot Grupo Proaco – Inbound + Outbound

Fecha: 2026-08-12 · **Flows:** inbound (cliente llama) y outbound (bot llama a leads) · **Juez:** Qwen 2.5 7B / 7B-Coder (Ollama local)

1. Inbound

Se evaluaron **13 llamadas inbound** con 4 suites: heurísticas deterministas, LLM-judges adicionales y las 7 reglas de Proaco con dos jueces (comparación de consistencia).

S1 · Heurísticas deterministas

Métrica		Promedio
~	URL de derivación	0.308
~	Saludo presente	0.308
⚠	Despedida presente	0.846
⚠	Sin loop de transferencia	0.923
⚠	Sin datos de AySA	0.923
⚠	Tono respetuoso	1.000
⚠	Adherencia a español	1.000

S2 · LLM-judges adicionales

Métrica		Promedio
⚠	Moderación	0.000
⚠	Frustración del usuario	0.094
✓	Correctitud de herramientas	0.300
~	Utilidad	0.323
~	Relevancia de respuesta	0.354
⚠	Compleitud de tarea	0.523
⚠	Compleitud de sesión	0.603
⚠	Coherencia conversacional	0.639

S3 · Reglas Proaco (juez qwen2.5:7b)

Métrica		Promedio
⚠	Pedido de contacto (una vez)	0.592
⚠	Saludo oficial	0.623
⚠	Despedida oficial	0.750
⚠	Detección de intent	0.754
⚠	Tono español rioplatense	0.819
⚠	Deriva a la web	0.831
⚠	Listado máximo 3	0.931

S3 · Reglas Proaco (juez qwen2.5-coder:7b)

Métrica		Promedio
~	Saludo oficial	0.350
~	Despedida oficial	0.492
⚠	Listado máximo 3	0.538
⚠	Pedido de contacto (una vez)	0.654
⚠	Detección de intent	0.765
⚠	Tono español rioplatense	0.865
⚠	Deriva a la web	0.885

2. Outbound

Se evaluaron 6 llamadas outbound (touchpoints de la campaña Grupo Proaco en Lula). Nota: al momento de la evaluación la campaña solo contiene las llamadas de QA inbound; no hay llamadas salientes reales todavía.

O1 · Reglas outbound (heurísticas)

Métrica		Promedio
✓	Ofrece agendar cita	0.000
✓	Pide consentimiento	0.000
✓	Menciona el motivo	0.167
⚠	Listado máximo 3	0.833
⚠	Se presenta como Proaco	1.000
⚠	Tono respetuoso	1.000
⚠	Maneja no-interés	1.000

O2 · Reglas outbound (LLM-judge)

Métrica		Promedio
✓	Agendamiento de cita (LLM)	0.000
✓	Ofrece agendar cita	0.000
✓	Pide consentimiento	0.000
✓	Cliente no interesado (LLM)	0.133
✓	Menciona el motivo	0.167
⚠	Listado máximo 3	0.833
⚠	Maneja no-interés	1.000
⚠	Tono respetuoso	1.000
⚠	Se presenta como Proaco	1.000

3. Detalle por llamada

Cada llamada tiene su propia carpeta en `evaluaciones/{flow}/{llamada_id}/` con `scores.json`, `resumen.md` y `transcripcion.txt`.

Inbound

Llamada	S1	S2	S3	S3
llamada-1	0.71	0.40	0.83	0.83
llamada-10	0.71	0.49	0.81	0.79
llamada-11	0.71	0.32	0.86	0.46
llamada-12	0.57	0.22	0.66	0.60
llamada-13	0.86	0.34	0.81	0.99
llamada-2	0.57	0.42	0.69	0.48
llamada-3	0.71	0.34	0.90	0.93
llamada-4	0.86	0.48	0.81	0.59
llamada-5	0.71	0.30	0.37	0.34
llamada-6	0.86	0.29	0.74	0.51
llamada-7	1.00	0.30	0.73	0.39
llamada-8	0.86	0.28	0.87	0.93
llamada-9	0.71	0.43	0.76	0.63

Outbound

Llamada	O1	O2
CA18a4abd08a	0.57	0.44
CA19ee8401e8	0.71	0.64
CA1cc4b3a43b	0.57	0.44
CAc57514332e	0.57	0.44
CAd7af8dc9b3	0.43	0.33
CAf8fa6d0fc1	0.57	0.44

4. Hallazgos

Métricas con promedio bajo (< 0.60):

Métrica	Promedio	Suite
inbound/pide_contacto_una_vez	0.592	Reglas Proaco (juez qwen2.5:7b)
outbound/ofrece_agendar_cita	0.000	O1 · Reglas outbound (heurísticas)
outbound/pide_consentimiento	0.000	O1 · Reglas outbound (heurísticas)
outbound/menciona_proposito	0.167	O1 · Reglas outbound (heurísticas)
outbound/agendamiento_cita	0.000	O2 · Reglas outbound (LLM-judge)
outbound/ofrece_agendar_cita	0.000	O2 · Reglas outbound (LLM-judge)
outbound/pide_consentimiento	0.000	O2 · Reglas outbound (LLM-judge)
outbound/cliente_no_interesado	0.133	O2 · Reglas outbound (LLM-judge)
outbound/menciona_proposito	0.167	O2 · Reglas outbound (LLM-judge)

Recomendaciones

- **Inbound saludo/deriva:** reforzar el saludo oficial al inicio y la derivación a la web cuando el bot no puede resolver.
- **Inbound despedida/pedido de contacto:** asegurar despedida oficial y pedido de datos una sola vez al cierre.
- **Outbound:** validar las reglas con llamadas salientes reales (la campaña todavía no tiene). Se espera `pide_consentimiento` bajo si el flow no lo implementa.

Resumen Ejecutivo para el Equipo

Evaluación Voicebot Proaco — Agosto 2026

Qué se evaluó: 13 llamadas inbound reales + 6 touchpoints outbound (QA) contra reglas de negocio Proaco.

Resultado general: Inbound **77% promedio** (reglas Proaco, juez qwen2.5:7b). Outbound **0% en métricas de flow saliente** (no hay llamadas outbound reales todavía).

✔ **Lo que funciona bien** (🟢 ≥ 0.75)

Métrica	Score	Estado
Listado máx 3 (juez1)	0.93	🟢 Excelente
Tono español rioplatense (juez1)	0.82	🟢 Bueno
Derivación a web (juez1)	0.83	🟢 Bueno
Detección de intent (juez1)	0.75	🟢 Límite
Tono español rioplatense (juez2)	0.87	🟢 Excelente
Derivación a web (juez2)	0.89	🟢 Excelente

⚠ **Qué hay que arreglar** (🟡 0.50–0.74 / 🔴 < 0.50)

Métrica	Score	Estado	Acción
Saludo oficial (juez1)	0.62	🟡 Regular	Prompt obligatorio + test
Pedido de contacto (juez1)	0.59	🟡 Regular	Exactly-once al cierre + test
Despedida oficial (juez1)	0.75	🟡 Límite	Fallback obligatorio
Saludo oficial (juez2)	0.35	🔴 Crítico	Revisar criterio juez2
Despedida oficial (juez2)	0.49	🔴 Crítico	Revisar criterio juez2
Listado máx 3 (juez2)	0.54	🟡 Regular	Revisar criterio juez2
Heurística maneja_no_interes	Falso positivo	🔴 Bug	Reescribir (match "gracias" saludo)

🚫 **Outbound — Sin datos reales** Las 6 llamadas son inbound de QA, no outbound.
Métricas de flow saliente = 0%. Próximo paso: configurar campaña outbound real en Lula con leads de prueba.

Roadmap (Próximos Sprints)

Sprint	Foco	Entregable	Tiempo
1	Inbound crítico	Saludo, contacto, despedida, heurística fix → >0.80 reglas	1-2 sem
2	Outbound real	Campaña Lula con leads → exportar → evaluar heurísticas + GEval	2-3 sem
3	Juez cloud + CI	Groq llama-3.3-70b (gratis) + pipeline automático en merge	1 sem

Artefactos listos - evaluaciones/inbound/llamada-{1..13}/ — scores.json, resumen.md, transcripcion.txt - evaluaciones/outbound/CA.../ — 6 carpetas - REPORTE_EVALUACION_PROACO.md — reporte completo - evaluaciones/resultados_completos.json — agregado para BI